

TESSERACT v2 / AEGIS Forecast Improvement Platform

Blueprint Actualizado — Reconstrucción Dirigida por el Repositorio

Versión 2.0 · Junio 2026 · Basado en evidencia de ejecución real

Tipo de documento:	Reconstrucción de blueprint dirigida por el repositorio
Fecha:	12 de junio de 2026
Modo:	Solo revisión — sin modificaciones a código, configs, datos, modelos ni rankings
Raíz del proyecto:	AEGIS-FORECASTING-IMPROVEMENT
Blueprint de referencia:	TESSERACT v2 Forecast Improvement Platform ---- Blueprint.pdf
Auditor:	Claude Opus 4.8 — Principal Forecasting Platform Architect

Toda afirmación de estado está respaldada por artefactos reales del repositorio. El README.md fue descartado como fuente de verdad.

Nota Metodológica — Evidencia

Toda afirmación de estado en este documento está respaldada por artefactos reales encontrados en el repositorio: configs en config/, código en python/model_lab/, salidas en outputs/model_lab/, y los dos audits en outputs/model_lab/audits/. El README.md de la raíz está desactualizado y fue descartado como fuente de verdad.

Reconciliación de hechos de datos (Stage 3 vs implementación)

Existe una diferencia legítima entre los hechos de datos crudos de Stage 3 y los hechos de la ejecución del baseline de Stage 5. No es un error — son dos planos distintos:

Hecho	Stage 3 (fuente cruda)	Stage 5 (ejecutado)	Evidencia
Entidades	45	39 (historia suficiente)	full_baseline_summary.csv, audits
Modelos baseline	16 ModelVersions (fuente)	7 modelos implementados	baseline_metrics_by_model.csv
ForecastVersion	2026-05-01 Enterprise	2026-05-01 Enterprise	consistente
Tabla métricas	forecast_substrate BE_hdd_region_metrics	misma (validación)	evaluation_source_summary.txt
Ventanas backtesting	—	454 (≈468 teóricas; ~14 de historia corta)	full_baseline_summary.csv, AUDIT #1

⚠ Atención

Las '16 ModelVersions del baseline' (fuente cruda) no se confirmaron desde la tabla de métricas. El baseline implementado y ejecutado en el Model Lab usa 7 modelos. Esta discrepancia debe documentarse antes de cualquier publicación externa.

A. Resumen del Blueprint Original

El blueprint original define una plataforma de evaluación de forecasting en 9 etapas cuya tesis central es: "TESSERACT actual = Baseline. Framework propuesto = candidato de mejora. Los datos deciden."

#	Etapas	Propósito original
0	Project Foundation	Estructura de carpetas, arranque de Shiny, base del repo
1	Vision & Wireframe	Visión ejecutiva + wireframes (docs/wireframes/)
2	Data Contract	Esquemas de datos fijos (forecasts, actuales, metrics, rankings, run_metadata, recommendations)
3	Baseline Replication / Evaluation Platform	Reproducir output TESSERACT + plataforma de evaluación (métricas, datasets)
4	Model Lab	Ejecutar modelos baseline + candidatos, ranking, comparación, torneo
5	Validation Lab &	Composite score, validación, gobierno, recomendaciones

#	Etapas	Propósito original
	Governance	
6	UI/UX + LLM Insights	UX ejecutivo + narrativas LLM (Ollama / Claude API)
7	Codebase Improvement	Deliverable G3 de mejora de código
8	Cierre / Entrega	Consolidación final

B. Estado Actual del Repositorio

Regla Arquitectónica — VERIFICADA Y CUMPLIDA

- **app.R:** shiny_app/app.R tiene 7 líneas (solo source() + shinyApp()). Cumple el límite de ≤ 30 líneas y la regla de solo orquestación.
- **Modularidad:** Shiny está modularizado en ui/, server/, modules/, R/.
- **Python:** Todo el procesamiento, métricas, modelos y rankings viven en python/ (model_lab/, evaluation/, ingestion/, transform/, utils/).
- **Verificación:** No se detectó cálculo de métricas en R.

Inventario de Evidencia Clave

config/ — 7 archivos

- execution.yaml: training_enabled: false, dry_run: true → triple-gate de ejecución activo.
- backtesting.yaml: walk-forward, horizonte 30 días, ventana expansiva, min 365 train / 30 test.
- ranking_policy.yaml: normalization.method: percentile_rank_within_entity_window, policy_status: design_only, policy_scope: baseline_models_only. Prohíbe explícitamente evaluar challengers.
-  **Alerta:** DERIVA DE CONFIGS CONFIRMADA: scoring_weights.yaml usa 6 métricas pero el ranking publicado usa ranking_metric_weights.csv con 5 métricas. Dos sistemas de pesos divergentes coexisten.

python/model_lab/models/ — 14 clases registradas

- Baseline implementados y ejecutados: arima_fixed_model, ets_current_model, linear_regression_model, fixed_growth_model (1.5/3/4/6).
- Challengers SOLO como placeholders: autoarima_model, theta_model, lightgbm_model, xgboost_model, nbeats_model, nhits_model, ets_model.

outputs/model_lab/ — evidencia de ejecución

- **Full baseline:** run full_baseline_20260611_103953 → 454 ventanas · 39 entidades · 7 modelos · 3,178 jobs · 0 fallos · 95,340 filas de forecast.
- **Métricas:** Motor de métricas (wMAPE, MAPE, RMSE, SMAPE, abs bias) calculado. Ranking policy, dry run y ranking_publication.csv publicados.
- **Audits:** AUDIT #1 (pre-training): APPROVED WITH CHANGES. AUDIT #2 (challenger readiness): BLOCKED.
- **Sin iniciar:** VACÍOS: tournament/, dashboard/, outputs/governance/, outputs/baseline/ — no iniciados.

-  **Riesgo:** tests/ está VACÍO — riesgo de regresión sin cobertura automatizada (señalado por ambos audits).

C. Estado Etapa por Etapa

Etapa 0 — Project Foundation

Estado: **Done**

Bloques implementados:

- Estructura de carpetas (AEGIS-FORECASTING-IMPROVEMENT/)
- setup.R, app.R (7 líneas), modularización Shiny
- Regla arquitectónica R-presentación / Python-procesamiento
- Python venv, pyodbc, pandas, Git repo inicializado

Bloques pendientes:

- Ninguno

Etapa 1 — Vision & Wireframe

Estado: **Done**

Bloques implementados:

- Definición de visión y wireframe ejecutivo
- Estructura docs/wireframes/ creada
- 6 tabs diseñados: Overview, Overlay, Accuracy, Models, Backtesting, Governance

Bloques pendientes:

- docs/wireframes/ vacío en disco (wireframes no versionados como artefactos — deuda menor)

Etapa 2 — Data Contract

Estado: **Done**

Bloques implementados:

- Contrato de datos confirmado contra fuente real (forecast_substrateBE_hdd_region + _region_metrics)
- ForecastVersion 2026-05-01 Enterprise, rangos actuales/forecasts confirmados
- evaluation_source_summary.txt generado

Bloques pendientes:

- Documentar formalmente la discrepancia 45 → 39 entidades y 16 → 7 modelos

Etapa 3 — Evaluation Platform

Estado: **Done**

Bloques implementados:

- Descubrimiento de fuentes (discover_evaluation_sources.py)
- Construcción del evaluation_dataset.csv
- Inventario de ventanas de backtest, validación de métricas oficiales
- Exports de dashboard de evaluación, fundación de la plataforma de evaluación

Bloques pendientes:

- Ninguno para la fundación — el motor de ranking semántico migró a Stage 5

Etapa 4 — Model Lab

Estado: **Active / Needs Revision**

Bloques implementados:

- Generación de 454 ventanas de backtesting + feature dataset
- Model registry (14 modelos) + controles de ejecución (triple-gate)
- 7 modelos baseline implementados y ejecutados (3,178 jobs, 0 fallos)
- Motor de métricas + sanity review + outlier investigation
- Ranking policy + dry run + publicación de ranking baseline
- AUDIT #1 (APPROVED WITH CHANGES) + AUDIT #2 (BLOCKED)

Bloques pendientes:

- Rediseño de semántica de benchmark (5.18)
- Naive + Seasonal Naive + MASE + RMSSE (5.19–5.22)
- Política forecast no-negativo + jerarquía de agregación (5.23–5.24)
- Framework de significancia estadística + no-tuning-leakage (5.25–5.26)
- AUDIT #3 + onboarding challengers + torneo + campeón (5.27–5.31)

Etapa 5 — Validation Lab & Governance

Estado: **Pending**

Bloques implementados:

- scoring_definitions.yaml y scoring_weights.yaml como diseño inicial (composite declarado inválido por AUDIT #1)

Bloques pendientes:

- Todo. Parte del gobierno (significancia, no-tuning-leakage) se adelantó como prerequisite de Stage 5

Etapa 6 — UI/UX + LLM Insights

Estado: **Pending**

Bloques implementados:

- Shiny modular base lista (app.R 7 líneas, ui/, server/, modules/, R/)
- outputs/model_lab/dashboard/ estructura creada

Bloques pendientes:

- UX ejecutivo final, integración LLM (Ollama / Azure OpenAI)
- Narrativas: Forecast Summary, Model Explanation, Recommendation Narrative, Executive Weekly Summary

Etapa 7 — Codebase Improvement

Estado: **Pending**

Bloques implementados:

- Ninguno

Bloques pendientes:

- Notebook consolidation, shared utilities, centralized config
- Output standardization, structured logging, PR/CODEOWNERS governance
- Suite de tests (tests/ vacío — deuda crítica)

Etapa 8 — Cierre / Entrega

Estado: Pending

Bloques implementados:

- Ninguno

Bloques pendientes:

- Consolidación final, deliverable G3

D. Posición Exacta Actual

Posición	Estamos actualmente en la Etapa 5 — Model Lab, sub-posición: gate de remediación previo a challengers (después de la publicación del ranking baseline y AUDIT #2, antes del rediseño de semántica de benchmark).
----------	--

Por qué — evidencia del repositorio

- El trabajo activo es sobre modelos baseline, ejecución baseline, semántica de benchmark, comparación de modelos y readiness de challengers — todos dominio explícito de Stage 5.
- La fundación de la plataforma de evaluación (Stage 4) ya está establecida. No debe devolverse trabajo a Stage 4.
- Evidencia de ejecución: full_baseline_20260611_103953 (454 × 7 = 3,178 jobs, 95,340 filas), ranking publicado, dos audits de Stage 5.
- El onboarding de challengers está BLOQUEADO (AUDIT #2). Las carpetas tournament/, dashboard/, governance/ están vacías, confirmando que el trabajo de challengers/torneo/gobierno aún no comenzó.

E. Evolución Respecto del Blueprint Original

E.1 — Evolución de Stage 4

Stage 4 dejó de ser solo 'Baseline Replication' y se consolidó como fundación de la Evaluation Platform: descubrimiento de fuentes, dataset canónico de evaluación, validación de métricas oficiales. La reproducción de modelos baseline migró a Stage 5.

E.2 — Evolución de Stage 5

Se expandió de 'correr candidatos' a un framework de ejecución baseline completo y auditable con triple-gate, manifest con cross-check de jobs, y audit logs append-only — corrigiendo el defecto de sobre-escritura detectado en AUDIT #1.

E.3 — Framework de ejecución baseline

7 modelos baseline implementados y ejecutados en 454 ventanas × 39 entidades = 3,178 jobs, 95,340 filas, 0 fallos. Pipeline verificado como leakage-clean por ambos audits.

E.4 — Rediseño dirigido por audit

AUDIT #1 (APPROVED WITH CHANGES): detectó composite inválido, métricas indefinidas, falta de manejo de actuals cero y sobre-escritura de historia. AUDIT #2 (BLOCKED): confirmó que forecasting y métricas son válidos pero el benchmark publicado no es válido como referencia fija.

E.5 — Semántica de benchmark (nuevo)

percentile_rank_within_entity_window es cohort-relativo. Contradicción rank-vs-accuracy confirmada: FixedGrowth_1_5 domina en TODAS las métricas crudas (wMAPE 4.9% vs ETS 18.2%) pero se publica 3°, mientras ETS_Current se publica 1°. Surge la separación: Absolute Benchmark Score ≠ Relative Tournament Rank.

E.6 — Adiciones de gobierno (adelantadas)

Framework de significancia estadística (MCB/Nemenyi/Diebold-Mariano), contrato de no-tuning-leakage para challengers ML/DL, política de forecast no-negativo (forecasts hasta -17.6M detectados), MASE/RMSSE con denominador naive.

E.7 — Política de ranking

Formalización de jerarquía de agregación (window → entity → cross-entity → global). De-colinealización del composite (wMAPE+MAPE+SMAPE = 65% del peso, redundantes). Tratamiento de la familia correlacionada FixedGrowth_* (4 de 7 modelos).

F. Blueprint Actualizado — Etapa 5 (Model Lab)

Leyenda:  Completado ·  Activo/Siguiente ·  Pendiente

#	Bloque	Estado	Notas
5.1	Generación de ventanas de backtesting (454)		
5.2	Construcción del feature dataset		
5.3	Model registry (14 modelos) + validación		
5.4	Controles de ejecución (triple-gate)		execution.yaml: training_enabled:false, dry_run:true
5.5	Contrato de ejecución + manifest + audit append-only		Corrige defecto de sobre-escritura detectado en AUDIT #1
5.6	Implementación de modelos baseline (7)		ARIMA, ETS, Linear, FixedGrowth 1.5/3/4/6
5.7	Smoke test		
5.8	Broader smoke test		
5.9	Pilot execution		
5.10	Full baseline execution		3,178 jobs · 39 entidades · 7 modelos · 0 fallos · 95,340 filas
5.11	Motor de métricas (wMAPE, MAPE, RMSE, SMAPE, abs bias)		
5.12	Metrics sanity review		
5.13	Outlier investigation (drilldown + root causes)		
5.14	Ranking policy (design_only)		policy_scope: baseline_models_only
5.15	Ranking dry run		
5.16	Baseline ranking publication		baseline_ranking_publication.csv
5.17	AUDIT #1 + AUDIT #2 (BLOCKED)		AUDIT #1: APPROVED WITH CHANGES · AUDIT #2: BLOCKED
5.18	Rediseño de semántica de benchmark	NEXT	Absolute Score vs Tournament Rank · ÚNICO BLOQUEADOR FORMAL
5.19	Modelo de referencia Naive		Prerequisito para denominador MASE/RMSSE
5.	Modelo de referencia		Ningún modelo se promueve si no supera al seasonal-

#	Bloque	Estado	Notas
20	Seasonal Naive		naive
5.21	Implementación de MASE		Denominador naive calculado sobre entrenamiento — nunca test
5.22	Implementación de RMSSE		Alternativa si importa el costo de errores grandes
5.23	Política de forecast no-negativo		Floor $\max(\text{forecast}, 0)$ + recálculo de métricas baseline
5.24	Formalización de jerarquía de agregación		Sobre métricas escaladas, no percentiles
5.25	Framework de significancia estadística		MCB / Nemenyi / Diebold-Mariano · rankings sin bandas no se publican
5.26	Contrato de no-tuning-leakage		Validación anidada + seeds/determinismo · ANTES de cualquier challenger
5.27	AUDIT #3 — Confirmación post-rediseño		9 criterios de éxito deben cumplirse
5.28	Onboarding de challengers		AutoARIMA, Theta, LightGBM, XGBoost, NBEATS, NHITS
5.29	Ejecución de challengers (sandbox primero)		
5.30	Torneo (cohorte conjunta baseline + challengers)		
5.31	Selección de campeón (con bandas de significancia)		

Decisiones de diseño obligatorias para bloques 5.18–5.22

- **Regla 1:** NO publicar `percentile_rank_within_entity_window` como score principal. Sirve para tournament rank relativo, no como benchmark estable.
- **Regla 2:** Adoptar UNA métrica primaria escalada (RMSSE o MASE) con denominador naive fijo calculado sobre la porción de entrenamiento de cada ventana (nunca sobre test → evita leakage).
- **Regla 3:** NO usar el composite ponderado 40/25/20/15. Pesos arbitrarios, redundancia ($wMAPE + SMAPE$) y mezcla de bias (dirección) dentro de un score de accuracy (magnitud).
- **Regla 4:** Un modelo es 'mejor' solo si gana en la métrica primaria Y no empeora en los guardrails (bias, % que supera al naive).

G. Blueprint Completo Actualizado — 9 Etapas

#	Etapas	Estado	Cambios incorporados
0	Project Foundation	Done	+ Regla arquitectónica: R/Shiny solo presentación, Python todo el procesamiento, app.R ≤ 30 líneas (actual: 7).
1	Vision & Wireframe	Done	Deuda menor: artefactos de wireframe no versionados en docs/wireframes/.
2	Data Contract	Done	Fuente real confirmada. Pendiente: documentar discrepancia 45 → 39 entidades / 16 → 7 modelos.
3	Evaluation Platform	Done	Reconceptualizada: fundación de evaluación (dataset canónico, validación de métricas oficiales). Reproducción de modelos baseline migró a Stage 5.
4	Model Lab	Active	Framework de ejecución baseline auditable y leakage-clean. Benchmark requiere rediseño (5.18–5.27) antes de challengers (5.28–5.31).
5	Validation Lab & Governance	Pending	Adelantos hacia Stage 5: significancia estadística, no-tuning-leakage, política no-negativo. Composite original declarado inválido por AUDIT #1.
6	UI/UX + LLM Insights	Pending	Shiny modular base lista. Dashboard de presentación y narrativas LLM pendientes.
7	Codebase Improvement	Pending	Deliverable G3. Incluir suite de tests (tests/ vacío) y unificación de configs de scoring.
8	Cierre / Entrega	Pending	Consolidación final.

Descubrimientos transversales incorporados al blueprint

- Triple-gate de ejecución y audit append-only (práctica MLOps).
- Política multi-step + reglas anti-leakage (multistep_forecasting.yaml).
- Separación conceptual: Absolute Benchmark Score ≠ Relative Tournament Rank.
- Anclaje de skill absoluto (Naive/Seasonal Naive + MASE/RMSSE).
- Significancia estadística y contrato no-tuning-leakage como gates pre-challenger.
- Deudas técnicas abiertas: tests/ vacío, deriva entre scoring_weights.yaml y ranking_metric_weights.csv, forecasts negativos sin floor.

H. Recomendación

Siguiente bloque

5.18 — Rediseño de Semántica de Benchmark

Por qué es el siguiente bloque

- **Bloqueador:** Es el ÚNICO bloqueador formal para challengers (AUDIT #2 = BLOCKED por C-1 cohort-relativo y C-2 rank-contradice-accuracy).
- **Dependencias:** Todos los bloques posteriores (5.19–5.31) dependen de la decisión semántica: MASE/RMSSE necesitan el denominador naive (5.19/5.20); la jerarquía de agregación (5.24) debe re-derivarse sobre métricas escaladas, no percentiles.
- **Alcance:** La capa de forecasting y métricas ya es válida (verificado por ambos audits). El esfuerzo se concentra solo en semántica de ranking + floor de no-negatividad.

Criterios de éxito (gate 5.27) — AUDIT #3 debe confirmar los 9 criterios

1. Score absoluto estable (cohort-independiente): el score baseline de cada modelo no cambia al agregar/quitar otros modelos.
2. Métrica primaria escalada (MASE o RMSSE) con denominador naive calculado sobre entrenamiento (test unitario que lo demuestre, evitando leakage en el denominador).
3. Naive y Seasonal Naive implementados y ejecutados. Ningún modelo se promueve si no supera al seasonal-naive.
4. Contradicción rank-vs-accuracy reconciliada y documentada. Publicar la vista de accuracy entity-balanced junto al rank.
5. Floor de no-negatividad aplicado uniformemente a todos los modelos y métricas baseline recalculadas tras el floor.
6. Jerarquía de agregación documentada (window → entity → global) sobre métricas escaladas.
7. Significancia estadística publicada con cada ranking (MCB/Nemenyi). Rankings sin bandas de confianza no se publican.
8. Contrato de no-tuning-leakage firmado (validación anidada para LightGBM/XGBoost/NBEATS/NHITS) + política de seeds/determinismo, ANTES de cualquier ejecución de challenger.
9. Deuda técnica mínima cerrada: unificar las dos configs de scoring en una sola fuente de verdad y poblar tests/ con tests de leakage, horizonte 30 días, no-future-actuals y determinismo de ranking.

Veredicto operativo

- **Publicación benchmark para challengers:** BLOQUEADA hasta completar 5.18–5.27.
- **Ejecución challengers en sandbox:** PERMITIDA una vez exista el score absoluto (5.18–5.22) — es la forma más barata de validar que el score es cohort-estable.
- **Producción challengers:** NO implementar challengers productivamente hasta que AUDIT #3 confirme los 9 criterios.

Documento generado en modo solo-revisión. No se modificó código, configs, datos, modelos ni rankings. Toda afirmación está respaldada por artefactos del repositorio.